

Predicción de diagnóstico de esquizofrenia mediante inteligencia artificial

Bóveda, A. Otegui¹, Pablo.², Galván Hugo³

¹⁻²G.H.R.A., ³Dpto. de Economía

¹⁻²Universidad de Buenos Aires, ³Universidad Nacional de Misiones, Argentina

{¹boveda, ²pablo}@gmail.com, ³hugo.galvan@fce.unam.edu.ar

May 10, 2023

1 Abstract

2 Introducción

- 2.1 Distintos abordajes de la esquizofrenia**
- 2.2 Psiquiatría computacional**
- 2.3 Convolutional Neural Networks**

3 Materiales y métodos

3.1 Base de datos

Para realizar este trabajo se utilizó un dataset de dominio público obtenido a partir del estudio Consortium for Neuropsychiatry Phenomics (CNP), el cual fue fundado por NIH Roadmap Initiative. De aquí se tomó una muestra imágenes de resonancia magnética mediante las siguientes técnicas:

- a) MRI ponderadas en T1 con el método MPRAGE ya que permite que se resalten los contrastes entre los tejidos, por lo que se utilizó para la segmentación y análisis de la anatomía y
- b) 64 Direction DWI (difusión ponderada en 64 direcciones, se usa para medir la difusión del agua en los tejidos cerebrales). Bilder et al. (2020)

Los pacientes analizados tenían entre 21-50 años de edad, todos de Los Ángeles y tenían que cumplir con los criterios de ser blancos, no hispanos ni latinos. Previamente se los escaneó para constatar que no padecieran enfermedades neurológicas, que no tomaran medicación y que no tengan historial de otras enfermedades mentales graves, ADHD ni ningún trastorno de ánimo ni ansiedad.

Para este trabajo en específico se eligieron 58 sujetos sanos y 58 sujetos con esquizofrenia diagnosticada.

3.2 Preprocesamiento y procesamiento de imágenes

Una vez escogidas las imágenes se realizó un preprocesamiento mediante el software FSL con el objetivo de corregir movimientos, distorsión, eliminar ruidos y segmentar tejidos para poder así separar las regiones de interés (ROI) y mejorar la precisión de las tractografías y mediciones.

Luego se procedió a procesar las imágenes mediante el programa DSI Studio para extraer características tractográficas. Puntualmente se evaluó la longitud, la fracción de anisotropía, la curvatura y el volumen de los tractos.

Todos estos datos obtenidos se utilizaron como inputs para el análisis de las imágenes mediante redes neuronales convolucionales.

3.3 Entrenamiento de la CNN

Primero se definió la arquitectura de la red neuronal con X cantidad de capas convolucionales, X capas de agrupación, X capas de normalización. Posterior a esto se compiló la CNN para definir la función de pérdida, el optimizador y las métricas de evaluación. Una vez definido todo esto se procedió a entrenar a la CNN: se ingresaron los inputs.

Se utilizó una fórmula de regresión logística para definir cada nodo (1). El nodo (y) es el resultado de multiplicar el peso (w) por un set de variables independientes (x), a eso se le sumó un bias. Luego a ese resultado se le aplicó la función de activación (f).

$$Y = f(wX + b) \quad (1)$$

Al principio se usaron valores random de w y b y se procedió a repetir el procedimiento para minimizar los errores de predicción de los valores de inputs outputs ya conocidos. Se repitió esto hasta reducir el error a un valor aceptable ($p < 0,05$)

Luego se procedió a mejorar el modelo agregándole más capas (n^o de capas) y nodos (n^o de nodos).

3.4 Análisis estadístico

Cuando se completó el entrenamiento del modelo se procedió a realizar el análisis estadístico mediante una prueba t de Student para comparar la diferencia entre el total de imágenes y el total de aciertos del modelo.

4 Resultados

5 Discusión

References

Bilder, R., Poldrack, R., Cannon, T., London, E., Freimer, N., Congdon, E., Karlsgodt, K., and Sabb, F. (2020). Ucla consortium for neuropsychiatric phenomics la5c study. *OpenNeuro.[Dataset]* doi, 10.